Documents et Données structurées

Pierre MARET
Université de Saint Etienne

Du documents aux données structurées et aux hypermedias

Chapitre
Du document numérique aux données structurées

Document numérique

- Document numérique
  - Ensemble cohérent de contenus numériques ayant une finalité

Document numérique

- Document numérique
  - Ensemble cohérent de contenus numériques ayant une finalité
- Autres notions autour du document :
  - Document Structuré
  - Structures logique et physique
  - Modèle de document
  - Multimédia
  - Hypermedia et web

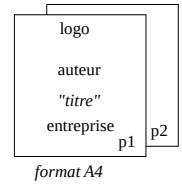
Document structuré

- Document non structuré: suite d'octets (ou caractères)
  - Un début, une fin
  - Suite de caractères "au kilomètre"
- Document structuré : une structure et des contenus
  - Parties et sous-parties : titre, auteur, date, chapitre, section, sous-section, citation, note, …
  - Contenus : informations, et associées à des parties

Structure logique et structure physique

La structure logique d'un document
Découpage logique, structuration en parties et sous-parties →

Dossier
-entête
-auteur
-logo
-titre
-société
-intro
-…



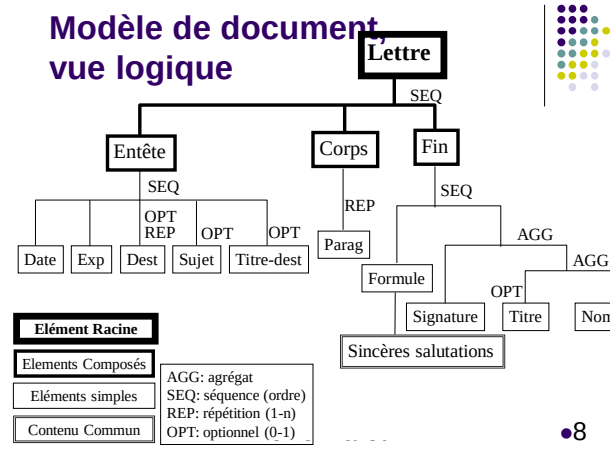
format A4

← La structure physique (layout)
Présentation : centrage, gras…
Découpage en pages

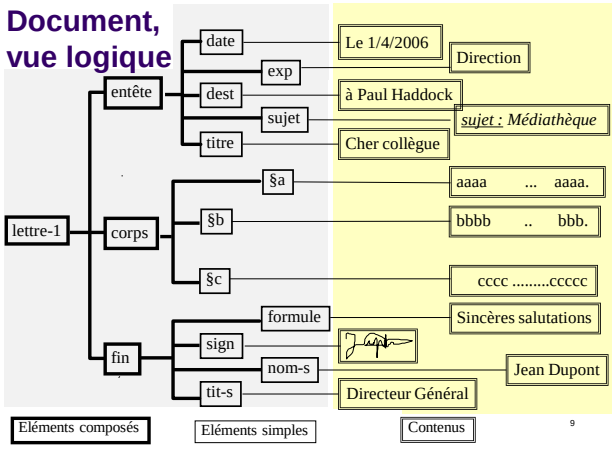
Modèle de document (Schema)

- Modèle de document
  - Définition d'une structure logique type
  - Parties éventuellement optionnelles ou répétées
  - Éventuels contenus par défaut (texte, image…)
  - Éventuels styles de présentation ou format(-age) associés aux parties
- Document
  - Instance d'un modèle de document
  - Avec les contenus et des styles de présentations

Modèle de document, vue logique



Document, vue logique



Document, vue physique

Le 1/4/2006

Direction

à Paul Haddock

sujet : Médiathèque

Cher collègue

aaaa

Convergence données-documents

- Construire des documents à partir de BDs
  - Les contenus : Valeur simple, Valeur composée (structures), Chaines de caractères, Objets complexes (données multimédia)
  - Les informations de structure : schéma des documents, liens entre des contenus (ex: liaisons entre pages)
  - La gestion de la persistance des informations (=rôle du SGBD)
  - Des documents à jour: création dynamique avec l'info directement issue de l'activité sur le SI (système d'information)
- Démultiplication: des contenus sur plusieurs bases de données et/ou serveurs

Extensions des SGBD

Des SGBD avec fonctions orientés "documents"

- Des structures de données de taille variable et possiblement très grandes
  BFILE, BLOB (binary file / binary large object) → images, fichiers
- Types complexes et définis par l'utilisateur
  CREATE OR REPLACE **TYPE TypeLettre** AS OBJECT
  (Entête VARCHAR, Corps TypeCorpsLettre, Fin VARCHAR…);
- Recherche avancée sur le texte intégral
  Rechercher les articles contenant le mot M1 ET les mots *souvent* utilisés avec M1
  Exemple sur MySQL : SELECT * FROM Lettres WHERE MATCH (Entête, Corps) AGAINST (M1 WITH QUERY EXPANSION);
  M1= "invitation". Récupère : "invitation Noël, soirée" / "invitations, repas, soirée" / "soirée musicale"

Extensions des SGBD (suite)

Des formats d'exportations des données

- CSV
- JSON
- XML

Utilité: migration de BD, construction de messages à envoyer, calculs, changement de format, etc.

Attention: perte !

- vérifications des *contraintes référentielles* (clés étrangères)
- *possibilité d'interrogation en SQL*

GED

- Gestion Électronique de Documents
  - Progiciel (Suite logicielle) dédié à la gestion des documents
- Adapté à des grandes organisations
- Fonctions d'une GED
  - Production (acquisition, création des documents)
  - Gestion (traitement, indexation, stockage, diffusion, échanges, conservation, manipulation)
  - Recherche d'informations
  - Consultation (visualiser, naviguer)

Complémentarité Doc-SGBD

Les documents (et la GED) sont des

-moyens de visualiser des données des BD (présentation soignées, données dynamiques)

-moyens de capturer des données dans des BD
Eviter de laisser diluer les informations dans les documents → structurer via des Formulaires, via des LLM

-moyens de traiter des données
La GED fournit des outils (diffusion, analyse, extraction… des contenus) plus spécialisés que ceux des SGBD

Complémentarité GED-SGBD

Convergence des outils de GED et des SGBD

- Intégration des outils documentaires dans les Systèmes d'Informations. La BD en arrière plan, le contenu est mis en valeur.
- Notion de "workflow" : flux, processus, étapes liées à un document
- Notion de "groupware" : logiciel pour le travail de groupe → outils collaboratifs
- Apport de la notion d'Assurance–Qualité: description des méthodes de travail pour une labellisation ISO 9000.

Autres notions

- Document retraitable / Document non retraitable
  - ex : fichier verrouillé en écriture
- Outils de traitements de documents (1964, IBM Allemagne)
  - MS-Word (1983), OpenOffice-Writer (2000), etc. : "peu" de prise en compte de la structure du document (mélangée avec le contenu)
    - WYSIWYG : what you see is what you get
  - Tex (1980), Latex : distinction forte contenu/présentation
  - Lyx : intermédiaire (document structuré avec Tex + interface *presque* Wysiwyg)

Mono et Multi-média

- Donnée
- Texte – brute ou enrichi (gras, italique, etc.)
- Formule (chimie, math)
- Image
  - Point par point (matrices de pixels = **pic**ture et **el**ement).
    Qualité : densité de pixel, nb de bits par pixel = nb de couleurs
    1 bit = 2 couleurs (ou 2 niveaux de gris) 4 bits = 16 couleurs
    8 bits = 256 couleurs (ou niveaux de gris) 24 bits = 16 millions
  - Vectorielle (issues d'une description de formes graphiques)
    TracerTrait(x, y)
- Son : reproduit (à partir d'un enregistrement) ou synthétisé (à partir de calculs)
- Vidéo : standard= 30 images / s + son

média = moyen

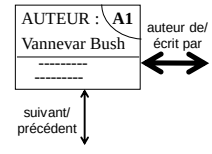
- Multimédia = combinaison de plusieurs moyens
- Moyens de représentation
  - *Texte, image (schéma, photographie, dessin), formule (mathématique, chimique, …), table, son (parole, musique, bruit), vidéo, …*
- Mais aussi moyens de …
  - …perception : *vue, ouie, touché, goût, odorat*
  - …présentation : *papier, écran, haut-parleur, pierre, …*
  - …stockage : *disque magnétique (disquette, disque dur, zip, …) disque optique (CD-ROM, CD-WORM, CD-R, DVD, …) bande magnétique, mémoire vive, mémoire morte, ….*
  - …transmission : *câble, ondes hertziennes, fibre,….*

Chapitre
Vers les hypermédias

Vers le document Web

- Les origines : hypertexte
  - 1945 (Bush, conseiller de Roosevelt) : système de gestion d'un réseau complexe de notes (papier, ...).
    Projet *MEMEX,* pas d'outils informatiques, fiches papier.
  - **Années 1960 (Engelbart, Nelson, ...) : utilisation de l'informatique, mot "hypertexte« , début de la souris**
- Les principes :
  - Ensemble structuré de noeuds et de liens
  - Noeuds ➔ contenus, associés à une *Unité Sémantique,* éventuellement typés
  - Liens ➔ structure (arbre = document, graphe, hypergraphe), éventuellement typés (composition, version, similaire à, voir aussi, référence, etc.)

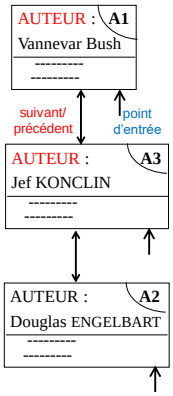
Hypertexte et document structuré



- Nœud
  - Elément minimal dans une structure logique
  - Possède titre, contenu (multimédias)
  - Méta-données: mot-clé, date, auteur…

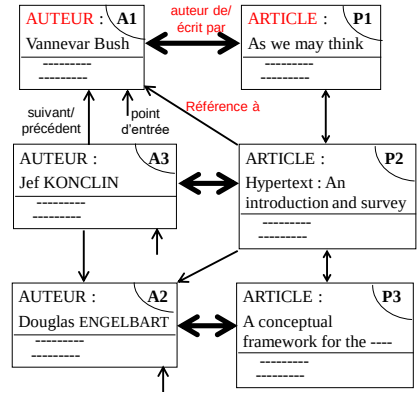
  Et
  - Liens pour la navigation : ancre (départ) + destination (cible)

Exemple d'hypertexte



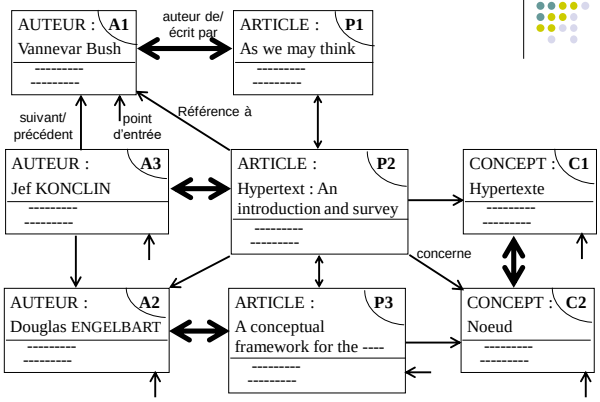
- Nœuds d'un même type
- Parcours « linéaire »: précédent/suivant
- Point d'entrée pour accès direct (atteindre un nœud par mot-clé, par exemple)

Exemple d'hypertexte

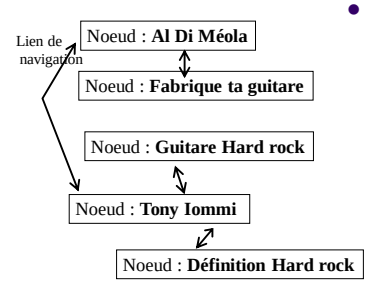


- Nœuds de différents types
- Liens avec une sémantique

Exemple d'hypertexte

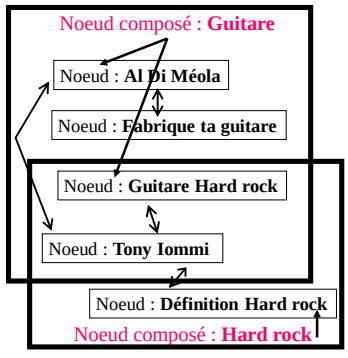


Notion de nœuds composés et simples



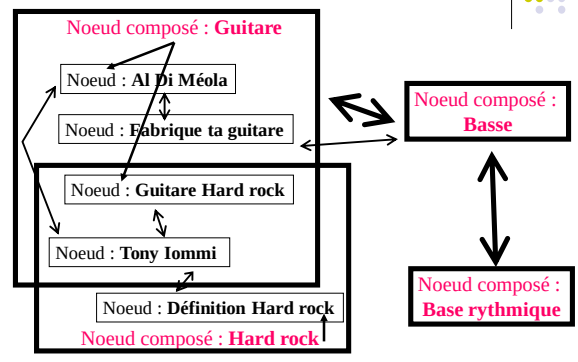
- Noeuds simples
  - Noeuds
  - Liens

Notion de nœuds composés et simples

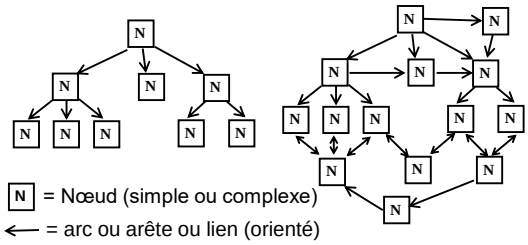


- Structure de nœuds composés

Notion de nœuds composés et simples



Arbre et graphe de nœuds



Evolutions de l'hypertexte

- Hypertexte : nœuds (documents) textuels et liaisons entre les noeuds
- Hypermédia : Les nœuds deviennent multimédia
- Hypermédia dynamique : les liaisons sont calculées (selon cheminement utilisateur ou autre…)
- Hypermédia multi-serveurs : les documents liés ne sont pas tous sur le même serveur

Hypermédia, Web

- World Wide Web : *"La Large Toile Mondiale"*
  - Système d'échange de documents multimédias sur Internet
  - Principes : documents disponibles sur des serveurs puis lus par des clients (=navigateurs)
  - Conçu en 1989 par Tim Berners-Lee *(au CERN)*
    - Objectif initial : échanges d'informations scientifiques (articles, rapports) au niveau mondial pour les chercheurs
  - Une amélioration de l'existant *(et non une révolution)* :
    - Accès plus convivial à des serveurs existants *(WAIS Wide Area Information Service, GOPHER prédécesseur de www, FTP File transfer protocol... existaient)*

Hypermédia, Web

- Web
  - Principes : documents disponibles sur des serveurs puis lus par des clients

Question: comment rendre les documents compréhensibles (interprétables) par le côté client?

Hypermédia, Web

- Web
  - Principes : documents disponibles sur des serveurs puis lus par des clients

Question: comment rendre les documents compréhensibles (interprétables) par le côté client?

  - Réponse : proposer et faire adopter un langage unique de codage des documents → HTML

HTML

- Bases : hypermédia multi-serveur
- Un langage d'écriture des documents
  - Structurer les documents en vue de les présenter
    - Structure intra-document : contenu et format
    - Structure inter-document : liens de références
- S'appuie sur des idées déjà connues
  - Hypertexte (1960'), hypermédia
  - Langages de balisage (années 70), dont SGML (Standard Generalized Markup Language) Un langage de description de documents dans le domaine de l'édition
  - Internet

Langages de balisage

- Document « enrichi » par des séquences textuelles prédéfinies indiquant la structure
- Mixe le contenu et la structure dans le document
- Des traitements automatisés sont possible lorsque l'analyseur connait le langage de balises

- Exemples: ?

Langages de balisage

- Document « enrichi » par des séquences textuelles prédéfinies indiquant la structure
- Mixe le contenu et la structure dans le document
- Des traitements automatisés sont possible lorsque l'analyseur connait le langage de balises

- Exemples:
  - LATEX avec \begin{*itemize*} \begin{*document*} \begin{*figure*}
  - HTML avec <head> <body> <a>
  - XML avec <TousMesAmis> <UnAmi>

HTML

- **H**yper**T**ext **M**arkup **L**anguage
  - Modèle pour la représentation d'hyperdocuments
    Mixe la structure logique d'un nœud = page (ex: <h1>), sa structure physique <head> et sa présentation ( )
  - Simplification du standard **SGML (langage de balises)**
  - En constante **évolution** :
    - **HTML-1 (1989)** : texte, des styles, des liens hypertextes
    - **HTML-2 (1994) :** + images, formulaires interactifs
    - **HTML-3 (1996)** : + graphiques vectoriels, son, applets
    - **HTML-4, DHTML (1998) :** + vidéo, CSS (présentation)
    - **XHTML (2000)** : reformulation de HTML selon XML
    - **HTML-5 (2012)** + multimedia et **HTML Living Standard**

De HTML à …

- Réussite incontestée de HTML et du Web
- Limites de HTML (qui ont facilité le début réussi)
  - Balises pré-définies, et orientées 'texte'
  - Syntaxe laxiste (erreurs d'écritures, robustesse des logiciels)= beaucoup de documents HTML sont invalides
  - Mélange de description physique et structurelle (avant CSS)
  - Pauvreté des liens (lien 'a' et 'link' – lien typé mais peu utilisé)

De HTML à …

Mais en fait, pour faire quoi ?

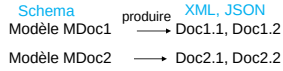
- Exprimer l'information, tout en évitant les ambiguïtés, et reliant des info entre elles
- Multi-domaine (pas spécifique à un métier)
- Partager l'information: échanges →commerce
- Présenter l'information
- Exploiter l'information

De HTML à XML, JSON…

- D'une réussite incontestée de HTML et du Web
- Aux limites de HTML (qui ont facilité sa réussite)
  - Balises pré-définies, et orientées 'texte'
  - Syntaxe laxiste (erreurs d'écritures, robustesse des logiciels)= beaucoup de documents HTML sont invalides
  - Mélange de description physique et structurelle (avant CSS)
  - Pauvreté des liens (lien 'a' et 'link' – lien typé mais peu utilisé)
- XML, JSON… pour généraliser
  - "Corrigent" des pb de HTML, et imposent une rigueur
  - Généralise, ouvre à grande variété d'applications
  - Offre plus de possibilités : définir ses propres balises
  - Développés et évolutions par le W3C (depuis 1997)

XML, JSON (très courte intro!)

- Des méta-langages : permettent de définir des modèles (= schémas) de documents



- Syntaxe plus riche et outils plus strictes
  - Liens
  - Notion de document "bien formé" (parseur, vérificateur)
- La diffusion des modèles de documents (schema) permet des échanges entre applications
- Possibilité de spécifier différentes présentations (layout) d'un même document

Nous avons vu…

- Document Structuré
- Structures logique et physique
- Modèle de document
- Convergence document et données, GED-SGBD
- Multimédia
  - Essentiellement au niveau "représentation"
- Hypermedia et web
  - Hypertexte
  - Hypergraphe
  - HTML vers XML, JSON