Documents et Données structurées

Pierre MARET
Université de Saint Etienne

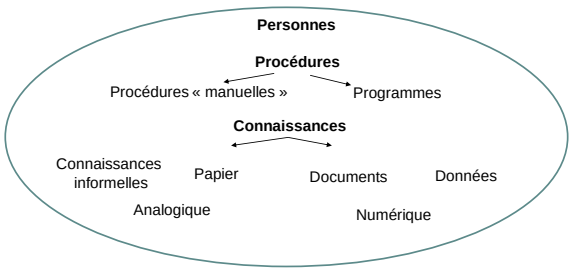
Partie 1
Introduction

Brainstorming

Documents et Données Structurées
C'est quoi?

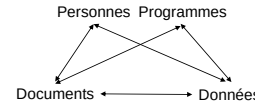
Brainstorming

C'est quoi le SI d'une organisation?



Brainstorming

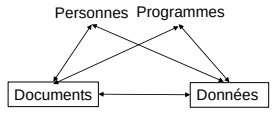
SI numérique



-production
-exploitation
-transformation
-présentation…

Brainstorming

SI numérique



Formats docx, txt xlsx, csv, R-DB

Et aussi : json, HTML, XML, jpg, pdf

Objet du cours

- Notion de document numérique
- Convergence documents-données
- Caractéristiques des contenus
- Formats de documents et de données structurées
- Processus de manipulation des documents et données

Sujet très actuel: nombreux "cours" en ligne

- Connaissances via LLM
- Formats HTML & co., XML, JSON…
- BD exports, conversions de formats
- Wikipedia, Wikidata
- Modélisation des données et connaissances, sémantique

Ce cours = construction pédagogique (un point de vue, une progression), permettant de s'orienter et d'apprendre encore par la suite…

Plan du cours

- Introduction
- Les contenus
- Du document numérique aux données structurées

Introduction. Usages du doc

- Le document est un regroupement d'informations (= des "contenus")
- Usages :
  - Formaliser: donner forme à des notions. Ecriture dessin, photo, oral (son, parole), film…
  - Mémoriser: conservation, trace. Tablettes, papyrus, papier, disque dur…
  - Traiter: analyse. Lecture, filtrage photo…
  - Transmettre: partager. Recopiage, Photocopie, Réseau informatique…

Introduction. Numérisation et besoins

Documents papier, image, son (= domaine analogique) : étape de numérisation

- Échantillonner (à une certaine fréquence)
- Coder

+ reconnaissance de formes pour détecter des lettres, des mots prononcés, des objets…

Introduction. Besoins généraux

Les besoins :

- Formalisation : besoin de **modèles de représentation**
- Mémorisation : besoin de **techniques de stockage**
- Traitements : besoin **d'algorithmes**
- Transmission : besoin de **protocoles**

Introduction Importance du domaine

- Tout *Savoir* passe par les documents
  - Moines copistes
  - Bibliothèques
  - Imprimerie
  - Wikipedia
  - LLMs
- Le PC, puis le Web, puis IA : amplification de l'usage du numérique
- Données et documents numériques -> partout. Technologies centrales, gros enjeux, de l'innovation, et du travail !

Introduction
Les étapes historiques

- Internet : interconnexion des réseau d'échanges au niveau mondial (1972)
- Informatique personnelle (IBM PC en 1981)
- Web : mise à disposition "infinie" de documents (1989)
- Contexte mondial d'hyper-communication vers 1990
  - Télécom: Réduction des coûts de communication
  - Mondialisation du commerce et libéralisme (recherche d'efficacité et de baisse des coûts)
- Wikipedia : généralisation de l'accès à la connaissance. 2001
- Chat GPT : 2022

Introduction
Vers des définitions

- C'est quoi une donnée?

Element d'information autonome, généralement accompagné d'un contexte pour son interprétabilité

Hors informaticiens : « mes data, mes documents, mes données, mes informations, mes fichiers… »
Gros mélange de vocabulaire!

Introduction
Vers des définitions

- C'est quoi un Document Numérique…
  - Une page web ?
    - Une application accessible via Facebook ?
  - Une photo, une vidéo, un texte et une photo ?
    - C'est tout ?
  - Une commande d'achat en ligne ?
    - Ça, un document? Mon œil !
  - Une base de données de produits ?
    - Ah bon ?

Introduction
Vers des définitions

- C'est quoi un Document Numérique…
  - Une page web ?
    - Une application accessible via Facebook ?
  - Une photo, une vidéo, un texte et une photo ?
    - C'est tout ?
  - Une commande d'achat en ligne ?
    - Ça, un document? Mon œil !
  - Une base de données de produits ?
    - Ah bon ?

Difficile à définir!

Introduction
Vers des définitions

Document numérique:

Ensemble cohérent d'informations numérisées ayant une finalité ou un sens.

Introduction - Modèle économique post-industriel

- Modèle économique en mutation
  - Information comme valeur marchande
  - Traitements automatisés, et en masse
  - Gestion des droits, questions d'éthique
  - Large diffusion / Confidentialité
  - Évolution de la chaîne éditoriale
  - Vente, location, usage unique/multiple, durée

Variété de modèles économiques. Evolutions.
Note: course en avant des investisseurs, risque d'éclatement des bulles spéculatives (≠ stabilité, confiance)

Introduction
Vers de nouveaux usages

- Génération automatique
- Lecture/analyse automatique, classification
- Recherche d'information, Q&A, compréhension
- Évaluation : validité, qualité, pertinence, confiance, prise en compte de la provenance.
- Souveraineté, sécurité
- Hyper-personnalisation (du contenu, de la présentation)

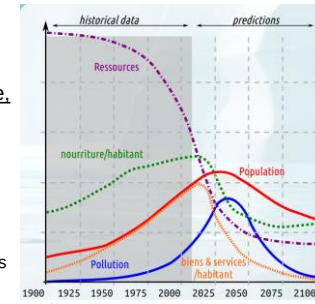
Nouvelles pratiques, nouveaux outils…
et tout ce que Vous imaginerez !
(l'histoire n'est pas finie !)

Limites du numérique

Alerte sur les risques d'affaissement.

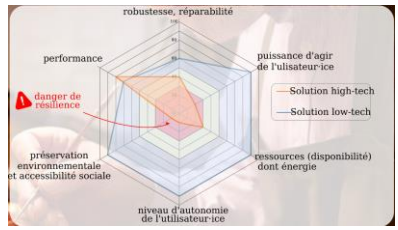
Nécessiter de développer la résilience, identifier et limiter nos dépendances

Figure tirée de
Les Limites à la croissance, Dennis Meadows, Donella Meadows et Jørgen Randers (mise à jour 2012)



Aller vers un "Mieux" plutôt que vers un "Plus"

Tiré de La convivialité, Illich, Giard, & Bardet (1973)



Fin de l'introduction

- Nous avons vu…
  - La transmission passe essentiellement par les documents et les données
  - Progression encore de la numérisation de la société
  - Internet/Web/IA accentue l'usage des données et documents numériques
  - Les techniques actuelles sont à connaitre
  - Un avenir encore à inventer, avec l'idée de résilience